

國家科學及技術委員會補助  
大專學生研究計畫研究成果報告

計 畫  
： Spine2D骨架自動生成  
名 稱

報 告 類 別 ： 成果報告  
執行計畫學生： 李宇哲  
學生計畫編號： NSTC 113-2813-C-011-056-E  
研 究 期 間 ： 113年07月01日至114年02月28日止，計8個月  
指 導 教 授 ： 戴文凱

處 理 方 式 ： 本計畫可公開查詢

執 行 單 位 ： 國立臺灣科技大學資訊工程系

中 華 民 國 114年02月22日

**目錄**

**中文摘要.....II**

**英文摘要..... III**

**前言 (Introduction).....1**

**研究目的 (Research Objectives)..... 1**

**文獻探討 (Related Work) .....2**

**研究方法 (Method) .....4**

**結果與討論 (Conclusion) .....8**

**參考文獻 (Reference) .....10**

## 摘要

在二維動畫製作的傳統流程中，動畫師常以逐幀繪製的方式呈現精緻的動畫畫面，但此過程相當耗時且費心。隨著數位內容持續成長，骨骼動畫技術逐漸受到業界重視。透過將角色分解為骨架與網格，加上網格頂點的權重分配，動畫師能有效減輕逐幀繪製的負擔。然而，現行的骨架設定程序仍需要專業知識與相當時間，對創作效率造成限制。

本研究以 Spine2D 工具為基礎，嘗試開發自動化骨架生成插件及相關流程。藉由機器學習與圖像處理技術，本系統可從靜態二維臉部圖片中自動辨識關鍵點，並建立對應的骨架與網格結構，同時匯出可供 Spine2D 載入的 JSON 專案檔，使動畫師能在已有初步骨架與網格配置的專案上直接微調與後製，進而提升製作速度與降低成本。在實務成果方面，我們已成功對靜態臉部圖片進行測試，驗證系統所產生的初步動畫在自然度與基本變形能力方面已有良好表現，顯示此自動化工具確實能在一定程度上協助創作者提高創作彈性與製作效率。

關鍵詞：骨骼動畫、自動化骨架生成、Spine2D、機器學習、圖像處理

## **Abstract**

In the traditional 2D animation production workflow, animators often create refined animation sequences through frame-by-frame drawing, which is both time-consuming and labor-intensive. As digital content continues to grow, skeletal animation techniques have gained increasing recognition in the industry. By decomposing characters into skeletons and meshes with weight assignments for mesh vertices, animators can significantly reduce the workload associated with frame-by-frame drawing. However, the current process of skeleton setup still requires professional expertise and substantial time investment, which limits creative efficiency.

This study is based on the Spine2D tool and aims to develop an automated skeleton generation plugin and workflow. Leveraging machine learning and image processing techniques, our system automatically identifies key points from static 2D facial images and constructs the corresponding skeletal and mesh structures. Additionally, it exports JSON project files that can be loaded into Spine2D, allowing animators to refine and post-process animations based on an initial skeleton and mesh configuration. In practical results, we have successfully tested our system on static facial images, demonstrating that the generated preliminary animations exhibit good naturalness and fundamental deformation capabilities. This indicates that our automated tool can effectively assist creators in enhancing creative flexibility and improving production efficiency.

**Keywords:** Skeletal Animation, Automated Skeleton Generation, Spine2D, Machine Learning, Image Processing

## 1 前言 (Introduction)

在二維動畫製作的傳統流程中，動畫師通常需要逐幀繪製角色的動作，以確保動畫的細膩與流暢。然而，這種方式極為耗時且對動畫師的技術要求較高，限制了動畫製作的效率與擴展性。因此，業界逐漸轉向使用骨骼動畫技術

(Skeletal Animation)，透過建立角色的骨架與網格，並使用權重控制變形，使角色能夠根據骨架變動生成動畫，進而減少逐幀繪製的負擔。

然而，現行的骨骼動畫技術仍然存在骨架設定成本高、網格變形手動調整困難等問題。尤其是在將靜態圖片轉換為動畫的應用場景中，動畫師仍需手動設定骨架與網格，使得整體製作流程效率不佳。近年來，隨著機器學習 (Machine Learning) 與圖像處理 (Image Processing) 技術的發展，自動化動畫生成的可能性逐漸提升。例如，MediaPipe [1] 和 BlazeFace [2] 等模型已經能夠準確識別人臉的關鍵點，並提供高效的臉部標記檢測能力，而 LivePortrait [3] 等技術則能透過學習驅動影片的運動資訊來生成高品質的臉部動畫。

本研究的核心目標是開發一套自動化骨架生成與動畫轉換系統，利用 MediaPipe 進行人臉關鍵點檢測、LivePortrait 進行補圖，以及 Spine2D 作為動畫編輯平台，讓靜態臉部圖片能夠根據驅動影片自動生成對應的動畫，並以 Spine2D 格式輸出，使動畫師能夠進行後續微調與加工。本研究不僅能降低骨架動畫的製作門檻，還能有效提升動畫的製作效率，在數位內容產業中具有實際應用價值。

## 2 研究目的 (Research Objectives)

本研究的主要目標是開發一種自動化工具，能夠將靜態人物圖片轉換為可編輯的骨骼動畫，具體目標包括：

### 2.1 自動建立骨架與網格結構：

透過 MediaPipe 偵測人臉關鍵點，生成適合於骨骼動畫的骨架與網格配置，減少手動設定成本。

### 2.2 補齊動作關鍵部位圖像：

使用 LivePortrait 與影像處理技術，針對嘴巴開合、眼球移動等動作需求，自動補全缺失的部位，確保動畫的完整性與真實性。

### 2.3 生成符合驅動影片動作的骨架動畫：

透過分析驅動影片的關鍵點變化，將動作資訊轉換為骨架與網格的運動參數，使靜態圖片能夠準確對應影片動作。

## 2.4 輸出可編輯的 Spine2D 格式：

將生成的骨架動畫轉換為 Spine2D 的 JSON 格式，使動畫師能夠在 Spine2D 內進行進一步的調整與優化，提高動畫製作的靈活性。

本研究透過整合機器學習與動畫技術，期望能夠提供一個高效且可編輯的動畫生成工具，減少傳統骨架設定的時間成本，並提升二維動畫製作的效率與可擴展性。

# 3 文獻探討 (Related Work)

## 3.1 Face landmarks detection

臉部標記點檢測(Face Landmarks Detection)是許多電腦視覺應用中的重要步驟，廣泛應用於臉部識別、表情分析與增強現實(AR)等領域。Google 提出的 MediaPipe 框架中，整合了 BlazeFace 模型，提供了一個高效且適合行動裝置的臉部檢測解決方案。

BlazeFace 是一個針對行動設備優化的輕量級人臉檢測模型，基於改進的 Single Shot MultiBox Detector (SSD) 架構，並使用 5x5 深度可分離卷積 (Depthwise Separable Convolutions) 作為特徵提取器，有效降低計算量並提升運行速度 (如 Figure 1 所示)。




Figure 1: 5x5 深度可分離卷積

BlazeFace 能夠輸出臉部邊界框與 6 個標記點，包括眼睛中心、鼻尖、嘴角與耳朵中心，這些標記點可作為後續臉部網格檢測與對齊的輸入 (如 Figure 2 所示)。此外，MediaPipe 框架透過 時間插值技術(Temporal Interpolation)，平滑標記點在連續影像幀之間的變化，確保輸出結果的穩定性與視覺連貫性。




Figure 2: 臉部邊界框與 6 個標記點

另一項重要的研究為 OpenFace [4]，該系統採用了 Conditional Local Neural Fields (CLNF) 模型進行臉部標記點檢測與追蹤，並針對臉部區域（如眼睛、嘴唇、眉毛）建立分層模型(Hierarchical Model)，分別訓練子模型以提升標記點的定位精度。OpenFace 提供了標記點檢測、頭部姿態估計及眼部凝視追蹤等功能，並在複雜場景中保持高效與穩定的性能（如 Figure 3 所示）。該系統透過臉部驗證步驟，有效檢測標記點追蹤中的誤差，並進一步確保長時間影片中的檢測準確性。




Figure 3: 標記點檢測、頭部姿態估計及眼部凝視追蹤功能

### 3.2 Portrait Animation

肖像動畫旨在將靜態人像圖片進行動畫化，實現逼真且富有表情的效果，同時追求足夠精確的圖片控制。影片驅動圖片的動畫方法主要可分為基於 diffusion model 與非基於 diffusion model 兩大類：

## Diffusion-based Portrait Animation

Diffusion Models 通過添加 Gaussian noise 破壞訓練數據 [5]，藉由學習反轉加 noising 的過程生成數據。隨後，diffusion model 被改進並推出 LDMs(Latent Diffusion Model) [6]，將訓練與推理過程轉移到壓縮的潛空間中，以提高計算效率。LDMs 已被廣泛應用於影片驅動的肖像、全身動畫，以及肢體動作的生成等方面，然而這類型技術多不可控生成效果。在生成過程中保留原圖像特徵成為重要課題，如 AnimateAnyone [7] 透過類似 ControlNet 的姿勢引導模組以及時間注意力架構達到保留特徵。X-Portrait 使用原始驅動影片，透過隱式關鍵點支援不同臉部間的變換。

## Non-Diffusion-based Portrait Animation

非 Diffusion Models 的方法使用隱式關鍵點 [8]，並使用光流方法獲得幀與幀之間的向量變化進行變形。FOMM(First Order Motion Model) [9] 在每個關鍵點附近執行一階泰勒展開，並使用局部仿射變換近似每個關鍵點鄰域的運動，而 Face vid2vid 更進一步拓展，引入三維隱式關鍵點實現自由視角的人像動畫。而由快手製作之 LivePortrait 更基於 Face vid2vid，額外加上拼接模組，使輸入圖片及驅動影片的關鍵點進行對齊與變形，達成效果極佳的合成結果。

## 4 研究方法 (Method)

本研究以一張靜態圖片與一段驅動影片為輸入，並產生與驅動影片動作一致之骨架動畫，最終輸出為可編輯之 Spine2D 動畫專案(JSON 格式)，包含經分層處理之圖片檔、對應骨架以及網格資訊，提供日後動畫師精緻化調整的基礎。

### 4.1 圖片拆解與補圖

在接收靜態圖片後，本研究首先執行「拆圖」及「補圖」兩階段處理。拆圖階段利用 Google 所推出之開源工具 MediaPipe 辨識人臉部位之關鍵點（如 Figure 4 所示），並依據關鍵點將輸入圖片分層切割。例如，系統將眼珠、眼白等容易發生位移但不容易發生變形之區域切割為獨立的圖層，以利後續的骨架動畫生成與調整。






Figure 4: MediaPipe 辨識關鍵點

補圖階段之目的在於完善原圖中因動作需求而欠缺的部位圖像。若靜態圖片中角色為閉嘴狀態，而驅動影片顯示需張口動作，本研究將先行擷取驅動影片之首幀，並根據該幀之嘴部位置與形狀資訊，以開源專案 LivePortrait 自動生成並補齊靜態圖片中口部內部的圖層，使後續的張嘴動態呈現更為真實，符合驅動影片所期望之口部變化（如 Figure 7 架構圖藍色區塊所示）。對於需額外補充的眼球、眼白等局部區域，則採用自行設計之影像處理方法進行補圖。眼球部分透過計算原切割區域中主體顏色，並以此色彩為基準生成正確形狀的眼球圖層。然而，本研究目前僅支援圓形眼球形態，尚未涵蓋如動畫角色之橢圓形眼球特性。此補圖流程使輸入之靜態圖片得以完備構成可因應驅動影片中各種動作所需之圖像資源。

## 4.2 骨架與網格生成

完成拆圖與補圖後，本研究利用 MediaPipe 所辨識之關鍵點資訊，建立對應的臉部骨架結構。此骨架之建立原則乃依據常見之 Spine2D 動畫製作邏輯：對於變形幅度較大或易呈現動態特徵之區域（如嘴巴、眉毛），設置對應的骨架控制點並綁定臉部網格點的權重；相較之下，鼻子、耳朵、臉頰等細節區域暫未納入骨架控制的範疇。骨架類型則因應部位特性而有差異，例如眼睛、嘴巴之骨架設為無長度與旋轉資訊的單點骨架，以實現靈活的變形；眉毛則使用具備旋轉、長度資訊的骨架，使該區域更易展現細微表情變化（如 Figure 5 的長骨架和 Figure 6 的骨架點）。




Figure 5: 眉毛長骨架




Figure 6: 眼球骨架點

本研究所建立之骨架彼此具備適當的繼承與階層關係，有助減輕動畫師後續調整整體結構的負擔。同時，研究亦利用 MediaPipe 關鍵點之位置生成網格 (mesh) 點，並為眉毛、嘴巴附近的網格點配屬相對應之權重(weights)，以決定骨架對網格變形之影響比例。對於未獨立拆圖的區域（如嘴巴、眉毛周圍），系統會自動為鄰近網格點分配最適合的骨架權重，使其在動畫變形時可呈現更自然而精確的動態表現。

#### 4.3 動作捕捉與動畫生成

在骨架與網格建置完成後，本研究透過 MediaPipe 偵測驅動影片中臉部關鍵點之移動與旋轉數據。取得此動作資訊後，首先執行標準化處理，以確保不同來源影片或角色特徵的動作資訊皆可合理套用至前述之骨架結構中。以眼珠的變化為例，本研究根據眼珠區域上下關鍵點的相對座標位置，計算眼球在驅動影片中的位移量並對應至靜態圖片所建立之骨架結構中，進而實現與驅動影片相符之目光移動動畫。




Figure 7: 架構圖

為提升最終動畫的平滑度與自然度，本研究於資料處理過程中加入卷積平滑 (Convolutional Smoothing) 及關鍵幀 (Keyframe) 擷取。透過卷積平滑可有效減少動作資訊中瞬時抖動所產生的雜訊，並藉由擷取動作達極端位置的時間點作為關鍵幀，系統可於關鍵幀之間進行曲線化平滑插值，使骨架動畫在動作過程中更為流暢自然。

最終，本研究將上述步驟整合後，輸出與驅動影片動作一致的骨架動畫。此動畫以可編輯之 Spine2D 動畫專案格式 (JSON) 呈現，並附有所有經分層與補圖處理後之圖像檔案及骨架、網格資訊。透過此方法，動畫師得以在此基礎上進行後續的細部調整與修正，達成快速且具品質的 2D 動畫製作流程。

## 5 結果與討論 (Conclusion)

### 5.1 結論與建議

在本研究中，我們的目標是實現一個流程：給定任意一張臉部圖片及帶有人臉的驅動影片後，生成根據驅動影片動作的臉部動畫，並將資訊轉換成 Spine2D 動畫軟體可再編輯格式。研究分為三個主要部份：

- (一) 基於 Mediapipe 進行臉部特徵拆解與標記（包括骨架與網格點座標）
- (二) 使用 LivePortrait 進行臉部補圖與對齊
- (三) 將對齊後的臉部動作資訊轉換為適用於 Spine2D 的骨架與變形參數，以實現可再編輯之動畫製作流程

根據最終實驗結果，我們的系統能夠在多數案例中成功將輸入的臉部圖片變形並對齊至驅動影片的對應動作。然而，在驅動影片動作急劇變化、加速度過大的情況下，生成的臉部動畫無法精確反應驅動影片的行為，主要原因為目前在幀與幀之間的平滑化尚不足，以至於在快速動作轉換中產生偏差。此外，由於在權重與變形比例上無法對每張圖片都找到最佳比例，有少數案例中嘴巴變化幅度過大或不足的現象，導致效果不如預期。

需要特別注意的是，如果輸入的臉部側臉角度過大，或嘴部張開度過小或過大時，由於基礎模型的訓練與校正參數主要針對較為中正角度且嘴形變化適中的情境，導致最終變形結果的精確度與自然度可能降低。

總結而言，我們在既有工具僅能生成對應驅動影片之臉部動畫的基礎上，開發出一套可供後續動畫軟體(Spine2D)再編輯的系統，以提升動畫師製作效率。在此研究目標達成後，我們期望未來能將該技術擴展至人體、動物以及任何物件之動態重建與動畫生成。




Figure 8、9: 成果圖

## 5.2 執行計畫過程遇到之困難或阻礙

在研究與開發過程中，我們遇到了多項技術挑戰，主要包括以下幾個方面：

### (一) 骨架與網格的最佳化問題

雖然 MediaPipe 提供了高效的關鍵點偵測能力，但這些關鍵點並非專門為骨架動畫設計，直接使用可能會導致骨架與網格結構不合理。我們需要額外設計關鍵點對應規則，確保骨架能夠適應動畫變形需求。

眉毛、嘴巴等區域的網格變形效果不佳，主要因為這些部位的變形較為細微且複雜，因此我們需要對這些區域的網格點權重進行額外調整，以提升動畫的自然度。

### (二) 補圖技術的適應性問題

由於驅動影片可能包含不同角度與動作變化，原始靜態圖片可能無法涵蓋所有動作所需的部位，例如張嘴時的牙齒、側臉時的臉頰邊緣等，這部分我們使用 LivePortrait 來補全缺失部位。

### (三) 驅動影片動作轉換的平滑度

在將驅動影片的動作資訊映射到靜態圖片的骨架時，我們發現當驅動影片的動作變化過大時（例如快速轉頭、張嘴），生成的動畫可能會產生明顯的錯誤或變形。了解決這個問題，我們引入了卷積平滑(Convolutional Smoothing)技術，降低突變的動作轉換，並透過關鍵幀(Keyframe)擷取來優化動作的流暢性。

## 6 參考文獻 (References)

- [1] C. Lugaresi, J. Tang, H. Nash, C. McClanahan, E. Uboweja, M. Hays, F. Zhang, C.-L. Chang, M. G. Yong, J. Lee, W.-T. Chang, W. Hua, M. Georg, and M. Grundmann, "MediaPipe: A Framework for Building Perception Pipelines."
- [2] V. Bazarevsky, Y. Kartynnik, A. Vakunov, K. Raveendran, and M. Grundmann, "BlazeFace: Sub-millisecond Neural Face Detection on Mobile GPUs."
- [3] J. Guo, D. Zhang, X. Liu, Z. Zhong, Y. Zhang, P. Wan, and D. Zhang, "LivePortrait: Efficient Portrait Animation with Stitching and Retargeting Control," Kuaishou Technology, University of Science and Technology of China, and Fudan University.
- [4] T. Baltrušaitis, P. Robinson, and L.-P. Morency, "OpenFace: An open source facial behavior analysis toolkit."
- [5] J. Sohl-Dickstein, E. A. Weiss, N. Maheswaranathan, and S. Ganguli, "Deep Unsupervised Learning using Nonequilibrium Thermodynamics."
- [6] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, "High-Resolution Image Synthesis with Latent Diffusion Models."
- [7] L. Hu, X. Gao, P. Zhang, K. Sun, B. Zhang, and L. Bo, "Animate Anyone: Consistent and Controllable Image-to-Video Synthesis for Character Animation," Institute for Intelligent Computing, Alibaba Group.
- [8] Y. Xie, H. Xu, G. Song, C. Wang, Y. Shi, and L. Luo, "X-Portrait: Expressive Portrait Animation with Hierarchical Motion Attention."
- [9] A. Siarohin, O. J. Woodford, J. Ren, M. Chai, and S. Tulyakov, "Motion Representations for Articulated Animation," DISI, University of Trento, Italy, and Snap Inc., Santa Monica, CA.